

李尧

高级数据工程师 / 大数据开发架构师

电话: 19301427029 | 邮箱: liyao_dg@163.com

本科 | 网络工程 | 淮南师范学院

8年大数据开发经验

个人优势

- **8年企业级大数据开发与数据平台建设经验**，具备海量数据处理、实时计算、离线数仓、数据治理及数据平台建设经验，熟悉 Hadoop、Spark、Flink、Kafka 等大数据技术体系。
 - 具备**多源异构数据接入、数据清洗转换、实时/离线数据加工及数据服务经验**，能够独立完成数据链路设计、开发、上线及生产问题排查。
 - 具备**高吞吐、低延迟数据处理及高并发系统开发经验**，参与建设日均20亿条级数据处理平台，核心实时链路延迟低于500ms。
 - 具备较强的**数据治理与数据质量建设能力**，有数据标准、数据质量规则、数据一致性校验、异常监控及数据质量提升经验，数据质量可用性达到99.7%。
 - 具备大规模集群部署、性能调优及复杂生产问题排查能力，能够解决数据倾斜、资源瓶颈、任务延迟、资源调度及系统稳定性等问题。
 - 熟悉 Java、SQL、Python、Shell 开发，掌握 Linux、Docker、Kubernetes，具备数据平台工程化及容器化部署经验。
 - 长期服务于金融等高数据质量要求行业，具备复杂业务数据建模、跨系统数据集成、数据标准化及数据质量保障经验，可将成熟的数据工程能力迁移至制造、供应链及工业数据场景。
-

专业技能

数据开发与计算

- 熟练使用 **Java、SQL、Shell** 进行数据开发，具备 Python 数据处理及工程开发能力。
- 熟悉 **Hadoop、Hive、Spark、Flink、Kafka、HBase** 等大数据生态。
- 熟悉 Kafka + Flink 实时计算链路，具备实时数据采集、清洗、转换、指标计算及实时数据处理经验。
- 熟悉离线数仓开发，具备 ODS/DWD/DWS/ADS 分层设计、数据建模及主题数据开发经验。

数据库与数据集成

- 熟悉 **MySQL、Oracle、Doris** 等数据库及分析型数据存储。
- 熟悉 SQL 优化、数据模型设计及海量数据查询优化。
- 具备多源异构数据接入、ETL/ELT、数据同步及数据标准化经验。
- 熟悉 DataX、Sqoop 等数据集成工具。

数据治理与平台工程

- 具备数据质量规则建设、数据一致性校验、异常监控、数据标准化及数据治理经验。
- 具备大规模集群部署、性能调优、任务稳定性保障及生产问题排查能力。
- 熟悉 Linux、Docker、Kubernetes，具备容器化部署及生产环境运维协作经验。
- 熟悉 Azkaban、Crontab 等任务调度方式。

工程能力

- 具备高并发、低延迟系统开发及压力测试经验。
- 能够参与技术架构设计、性能优化、技术方案编写及项目落地。
- 具备跨团队沟通及复杂业务需求分析能力。

工作经历

广州吉信网络科技有限公司 | 大数据开发架构师

反电信诈骗项目组 | 2023.02 - 2026.03

- 主导海量多源数据处理平台的架构设计、开发与迭代，平台日均处理数据量达到 **10TB+**。
- 设计并落地流批一体数据处理架构，支持实时数据处理、实时预警及离线分析场景，推动核心业务响应时间缩短至 **5秒以内**。
- 负责多源异构数据接入及数据加工，基于 Kafka、Flink、Spark 等技术构建实时及离线数据处理链路。
- 负责数据平台治理及数据质量管理体系建设，制定数据标准及质量规则，平台数据可用性达到 **99.7%**。
- 参与实时指标体系、数据模型及数据处理逻辑设计，支撑下游数据分析及业务应用。
- 负责生产环境性能优化及稳定性保障，处理数据倾斜、资源瓶颈、任务延迟等复杂问题。
- 参与集群压测、灾备及高峰场景稳定性方案设计，保障平台持续稳定运行。

悦锦软件系统（上海）有限公司 | ETL开发工程师

技术部 | 2021.09 - 2022.10

- 参与大型银行核心业务数据处理及数据集成项目，负责多源业务数据的抽取、清洗、转换及标准化处理。
- 基于 Oracle、PL/SQL、DataX 等技术构建 ETL 数据处理流程，完成海量业务数据的集中加工。
- 负责数据质量规则设计及数据一致性校验，建立完整性、逻辑性及一致性等多维度数据检查机制。
- 参与数据迁移及系统切换工作，分析不同系统间数据结构、字段映射及业务规则差异。
- 负责批量数据任务调度、运行监控及异常问题排查，保障数据任务稳定运行。

第四范式 | 数据开发工程师

交付一部 | 2019.04 - 2021.08

- 负责大型企业数据平台的数据接入、数据加工及指标开发，参与实时数据处理及数据应用建设。
- 负责多源业务数据接入及数据预处理，建立统一的数据接入、清洗及校验机制。

- 基于 Spark、Java、SQL 等技术完成海量数据处理及业务指标开发。
- 参与高并发实时数据处理系统的架构部署、性能调优及压力测试。
- 负责数据处理服务 Kubernetes 容器化部署及生产环境稳定性保障。
- 参与 NLP 数据处理项目，负责非结构化文本解析、数据预处理、数据集构建及模型服务相关开发。

欧电云科技（上海）有限公司 | 大数据开发工程师

技术部 | 2018.07 - 2019.03

- 负责企业业务数据指标开发及大数据处理逻辑优化。
- 基于大数据平台完成客户增量数据接入、清洗及加工。
- 优化数据指标计算逻辑及资源分配策略，减少数据计算时间。
- 参与产品前后端功能开发及生产问题排查。

核心项目经历

海量多源实时数据处理与分析平台

大数据开发架构师 | 2023.02 - 2026.03

项目描述

面向海量多源异构数据处理场景，建设集数据采集、实时计算、离线计算、数据治理及数据分析于一体的数据处理平台，实现多源数据统一接入、实时加工、指标计算及数据服务。

项目职责

1. 基于 **Hadoop + Spark + Flink** 构建离线与实时一体化数据处理架构，支持日均 **20亿条级数据** 稳定处理。
2. 基于 **Kafka + Flink** 构建多源异构数据实时接入链路，实现数据采集、清洗、转换及实时指标计算，核心链路延迟控制在 **500ms以内**。
3. 负责数据仓库及主题数据模型设计，完成多源业务数据标准化、统一编码及数据加工，支撑下游数据分析及数据应用。
4. 建立数据质量管理体系，设计完整性、一致性、准确性等质量校验规则，并建设异常监控机制，使数据一致性问题减少 **85%**。
5. 设计并开发20+核心实时指标，支撑实时数据分析及异常行为识别等业务场景。
6. 负责 Spark/Flink 数据处理任务性能优化及资源调度，解决数据倾斜、资源瓶颈、任务延迟等生产问题。
7. 负责生产环境集群压测及稳定性保障，参与高峰场景及灾备方案设计。

项目成果

- 平台实现日均 **20亿条级数据** 稳定处理。
- 实时数据链路延迟低于 **500ms**。
- 数据一致性问题减少 **85%**。
- 建立数据质量标准及监控机制，平台数据可用性达到 **99.7%**。
- 支撑实时数据分析、指标计算及下游数据应用。

核心技术： Hadoop、Spark、Hive、Flink、Kafka、Doris、MySQL、Java、Python、Kubernetes

企业级数据集成与数据质量治理平台

ETL数据工程师 | 2021.09 - 2022.10

项目描述

建设企业级数据集成及数据治理处理流程，实现核心业务系统数据的统一抽取、清洗、转换、标准化及质量校验，为下游数据应用提供稳定、准确的数据基础。

项目职责

1. 基于 Oracle 数据库设计及开发高性能 ETL 数据处理流程，实现多维业务数据的自动化抽取、集中及整合。
2. 负责原始业务数据清洗、转换及标准化，建立完整性、一致性、逻辑性等 **50+项数据质量检查规则**。
3. 设计数据质量监控及异常预警机制，对数据加工过程进行自动化监控。
4. 分析不同业务系统间的数据结构、字段映射及业务规则差异，参与系统数据迁移及切换方案设计。
5. 参与批量数据任务调度及依赖管理，保障海量数据稳定处理。

项目成果

- 实现日均**百万级数据**稳定处理。
- 数据报送成功率及准确率达到 **100%**。
- 数据质量及异常监控体系有效提升数据处理稳定性。
- 完成新旧系统数据迁移及切换，保障业务连续性及数据完整性。

核心技术： Oracle、PL/SQL、Shell、DataX、Crontab

高并发实时数据处理与性能优化项目

开发工程师 | 2021.04

项目描述

面向高并发实时数据处理场景，在有限集群资源条件下完成实时模型服务部署、性能调优及压力测试，验证系统在高TPS及长时间运行场景下的稳定性。

项目职责

- 负责实时数据处理系统架构设计及部署。
- 针对高并发场景进行资源调度、并发策略及性能优化。
- 设计并实施压力测试方案，分析系统吞吐量、响应时间及资源使用情况。
- 参与技术方案编写、测试结果分析及项目技术汇报。

项目成果

- **5000 TPS** 场景下持续稳定运行 **12小时**。
- 复杂场景单独支撑 **20000 TPS** 并发请求，稳定运行15分钟。
- 混合场景 **20000 TPS** 压力下稳定运行15分钟，响应时间保持在 **200ms以内**。
- 通过资源优化及并发策略调整，在有限集群资源下完成全部性能指标。

核心能力： 高并发、性能优化、压力测试、资源调度、稳定性保障

NLP智能数据处理项目

数据开发 / NLP算法工程师 | 2020.03 - 2021.03

项目描述

针对企业非结构化文档数据处理场景，建设从文档解析、数据清洗、样本构建、模型训练到模型服务的自动化处理流程。

项目职责

- 设计 Word 文档解析及文本预处理流程，完成非结构化数据清洗及结构化处理。
- 开发敏感信息脱敏模块，保障数据安全及数据可用性。
- 制定数据标注规范并完成数万条关系样本的数据集构建。
- 基于 PyTorch、BERT+CRF 完成文本实体及关系识别模型开发。
- 将数据预处理、模型训练、评估及模型更新整合为自动化流水线。
- 基于 Kubernetes 完成模型服务部署及线上服务封装。

项目成果

- 人工审核时间由平均30分钟缩短至 **5秒以内**。
- 模型测试集 F1 值超过 **92%**。
- 建立模型数据处理、训练、评估及版本管理自动化流程。

核心技术： Python、Java、PyTorch、BERT、CRF、Kubernetes

AI实时数据处理与特征工程项目

数据开发工程师 | 2019.04 - 2020.03

项目职责

- 使用 Java 开发分布式文件处理程序，对大规模数据文件进行切分及并行处理，使数据准备时间缩短约 **70%**。
- 建立统一数据接入及数据校验机制，保障上游数据完整性及一致性。
- 基于 Kubernetes 完成数据处理服务容器化部署，实现高可用及弹性扩展。
- 基于用户行为、交易时序等多维数据开发 **30+指标**，完成特征工程及指标筛选。
- 建立模型数据自动更新及效果监控机制，实现数据处理、模型训练及模型更新流程自动化。

项目成果

- 数据准备时间缩短约 **70%**。
- 欺诈识别准确率提升约 **25%**，误报率降低 **18%**。
- 模型迭代周期由约2周缩短至 **4小时以内**。

核心技术：Java、SQL、Spark、Kubernetes

教育经历

淮南师范学院

网络工程 | 本科 | 全日制

2014.09 - 2018.07

求职方向

优先方向：

- 高级数据工程师
- 高级大数据开发工程师
- 数据平台工程师
- 大数据开发架构师

目标行业：

- 半导体
- 智能制造
- 汽车及新能源
- 工业互联网
- 企业数字化
- 数据平台/数据中台

核心竞争力：

海量数据处理 | 实时计算 | 数据平台 | 数据仓库 | 数据治理 | 多源数据集成 | 性能优化 |
高并发 | Kubernetes | 工程化落地